

Uma Justificativa Metodológica para a Seleção de uma Suíte Diversificada de Meta-heurísticas: Referências Fundamentais e Seminais

A seleção de um conjunto de algoritmos para análise comparativa em ciência da computação, particularmente no domínio da otimização, é uma decisão metodológica fundamental que exige uma justificativa rigorosa. Uma abordagem que seleciona algoritmos de forma ad-hoc corre o risco de produzir resultados de escopo limitado ou vieses não intencionais. Em contrapartida, uma estratégia metodologicamente sólida envolve a seleção de um conjunto de algoritmos que representem paradigmas de busca fundamentalmente distintos. Esta abordagem não apenas garante uma cobertura abrangente do espaço de estratégias de solução, mas também permite extrair conclusões mais profundas sobre a natureza do problema em estudo, identificando quais filosofias de busca são inerentemente mais adequadas para sua estrutura.

Este relatório apresenta uma justificativa bibliográfica para a seleção de quatro meta-heurísticas canônicas: Algoritmo Genético (GA), Simulated Annealing (SA), Iterated Local Search (ILS) e Greedy Randomized Adaptive Search Procedure (GRASP). O argumento central é que esta suíte não é arbitrária, mas sim uma escolha deliberada que abrange três paradigmas de otimização bem estabelecidos e distintos: o paradigma populacional, o paradigma de busca por trajetória e o paradigma construtivo. Ao estabelecer a base teórica e as contribuições seminais de cada algoritmo dentro de seu respectivo paradigma, este relatório demonstra a robustez e a solidez metodológica desta seleção. A Tabela 1 a seguir fornece um mapa conceitual que estrutura o argumento central do relatório, alinhando cada meta-heurística ao seu paradigma, princípio de funcionamento e referência-chave.

Tabela 1: Classificação das Meta-heurísticas Seleccionadas por Paradigma de Otimização

Paradigma	Meta-heurística	Princípio Central	Referência-Chave/Se minal
Populacional	Algoritmo Genético	Evolui uma população	Holland (1975)

	(GA)	de soluções através de seleção, cruzamento e mutação.	
Busca por Trajetória	Simulated Annealing (SA)	Percorre o espaço de soluções aceitando probabilisticamente movimentos de piora para escapar de ótimos locais.	Kirkpatrick et al. (1983)
	Iterated Local Search (ILS)	Aplica iterativamente perturbações para escapar de ótimos locais e busca local para intensificar a busca.	Lourenço et al. (2019)
Construtivo	GRASP	Constrói soluções do zero de forma gulosa e aleatorizada, seguida por uma fase de refinamento.	Feo & Resende (1995)

Base Fundamental para a Classificação de Meta-heurísticas

A validade da seleção de uma suíte de algoritmos representativa depende da existência de uma taxonomia acadêmica robusta e amplamente aceita. No campo da otimização, a classificação de meta-heurísticas em paradigmas distintos não é um mero exercício descritivo; é uma ferramenta analítica essencial para compreender o comportamento da busca, os pontos fortes e as limitações de diferentes abordagens.

Uma meta-heurística é formalmente definida como um framework algorítmico de alto nível, independente do problema, que fornece um conjunto de diretrizes ou estratégias para desenvolver algoritmos de otimização heurísticos específicos.¹ O prefixo "meta" indica que estas são estratégias "de nível superior" que orquestram a interação entre procedimentos de melhoria local e mecanismos de mais alto nível

para escapar de ótimos locais e realizar uma busca robusta no espaço de soluções.² A capacidade de escapar de ótimos locais é, de fato, a característica que define uma meta-heurística e a distingue de heurísticas de busca local simples, como o hill-climbing, que terminam assim que encontram uma solução da qual nenhuma melhoria local é possível.¹

A maturidade do campo é evidenciada pela existência de compêndios de referência, como o *Handbook of Metaheuristics*, que já se encontra em sua terceira edição.² Tais publicações, juntamente com numerosos artigos de survey¹, organizam o conhecimento do domínio em torno de classes de algoritmos, solidificando a validade de uma abordagem taxonômica. A classificação mais fundamental, adotada por grande parte da comunidade acadêmica, distingue os métodos com base em como eles gerenciam e manipulam as soluções durante o processo de busca.¹ As três classes principais são:

1. **Métodos Baseados em População:** Estes algoritmos mantêm e evoluem um conjunto (ou população) de soluções simultaneamente. A busca progride através da interação e combinação de informações entre estas soluções, como observado nos Algoritmos Genéticos.¹
2. **Métodos de Busca por Trajetória:** Também conhecidos como meta-heurísticas de busca local de solução única, estes métodos focam em melhorar iterativamente uma única solução. Eles traçam uma trajetória através do espaço de soluções, começando de um ponto inicial e movendo-se para soluções vizinhas. Simulated Annealing e Iterated Local Search são exemplos canônicos.¹
3. **Métodos Construtivos:** Em vez de melhorar soluções completas existentes, estes métodos constroem soluções a partir de seus componentes constituintes, um elemento de cada vez. O GRASP é um exemplo proeminente desta abordagem.¹

Uma análise da literatura recente, especialmente nas edições mais novas do *Handbook of Metaheuristics*, revela uma tendência proeminente em direção à hibridização — a combinação de componentes de diferentes paradigmas para explorar suas sinergias.² Por exemplo, algoritmos meméticos combinam a busca global de um Algoritmo Genético com a intensificação de uma busca local⁵, e o próprio GRASP é inerentemente um híbrido de construção e busca local.⁹ À primeira vista, a escolha de algoritmos "puros" ou arquetípicos, como GA, SA e ILS, poderia parecer desatualizada em face dessa tendência. No entanto, essa escolha representa uma estratégia metodológica deliberada e poderosa. Ao selecionar exemplares claros de paradigmas distintos, um pesquisador estabelece um conjunto de

baselines fortes e não sobrepostos. Isso permite uma análise clara e inequívoca de como as filosofias de busca fundamentais (evolutiva, de trajetória probabilística, de trajetória baseada em perturbação e construtiva) se comportam em um determinado problema. A compreensão obtida a partir desses *baselines* é um pré-requisito para o projeto informado e a avaliação de abordagens híbridas mais complexas. Portanto, a seleção desta suíte não é um olhar para o passado, mas sim a construção de uma base fundamental sobre a qual pesquisas futuras e mais complexas podem ser edificadas.

O Paradigma Populacional: Algoritmo Genético (GA)

O Algoritmo Genético (GA) é o arquétipo do paradigma de otimização baseado em população. Sua abordagem é inspirada diretamente nos princípios da evolução natural e da genética, onde uma população de indivíduos (soluções) se adapta a um ambiente (a função objetivo) ao longo de gerações.⁴ O processo opera sobre uma população de soluções candidatas, aplicando operadores genéticos como a

seleção, que favorece os indivíduos mais aptos; o *crossover* (ou recombinação), que combina o material genético de dois pais para criar descendentes; e a *mutação*, que introduz pequenas alterações aleatórias para manter a diversidade genética e evitar a convergência prematura.⁵

A relevância do GA como um pilar da computação evolucionária não se deve apenas à sua elegante metáfora biológica, mas à sua robusta base teórica, estabelecida na obra seminal de John H. Holland.

1.

Snippet de código

```
@book{Holland1975,  
  author = {John H. Holland},  
  title = {Adaptation in Natural and Artificial Systems: An Introductory Analysis with  
Applications to Biology, Control, and Artificial Intelligence},
```

```
publisher = {University of Michigan Press},  
year      = {1975},  
address   = {Ann Arbor, MI},  
isbn       = {0472084607}  
}
```

- **Relevância:** Este livro é a obra fundadora que introduziu os Algoritmos Genéticos. Sua importância transcende a mera descrição de um algoritmo; ele apresenta uma nova teoria matemática da adaptação em sistemas complexos.¹⁰ A contribuição central de Holland foi a introdução do conceito de *schemata* (esquemas), ou blocos de construção, que são padrões de baixo nível dentro das soluções (cromossomos). Ele demonstrou matematicamente, através do Teorema do Esquema, como um GA processa um número exponencial de esquemas de forma implícita e paralela, mesmo operando em uma população de tamanho polinomial. Isso elevou o GA de uma simples heurística inspirada na natureza para um método de busca com uma explicação teórica sólida sobre por que e como ele explora eficientemente o espaço de soluções, recombina blocos de construção promissores para formar soluções cada vez melhores.¹¹ A seleção do GA é, portanto, justificada não apenas por sua natureza populacional, mas por representar o paradigma da busca baseada na recombinação de blocos de construção, fundamentada na teoria do processamento implícito de esquemas.

Para consolidar a justificativa, uma referência que tornou as ideias de Holland amplamente acessíveis e aplicáveis é fundamental.

2.

Snippet de código

```
@book{Goldberg1989,  
  author = {David E. Goldberg},  
  title  = {Genetic Algorithms in Search, Optimization, and Machine Learning},  
  publisher = {Addison-Wesley},  
  year   = {1989},  
  address = {Reading, MA},  
  isbn   = {0201157675}}
```

}

- **Relevância:** O livro de Goldberg é considerado o texto clássico que popularizou os Algoritmos Genéticos, traduzindo as fundações teóricas de Holland em um guia prático para cientistas e engenheiros.¹ Ele detalhou os mecanismos, as escolhas de implementação e as aplicações que solidificaram o GA como uma ferramenta padrão em otimização. Incluir esta referência justifica a escolha do GA não apenas com base em sua origem teórica, mas também em seu status estabelecido como um método prático e amplamente utilizado na comunidade de pesquisa.

O Paradigma de Busca por Trajetória

As meta-heurísticas de busca por trajetória operam modificando iterativamente uma única solução candidata, criando um caminho ou trajetória através do espaço de soluções. Embora compartilhem essa característica fundamental, os mecanismos que utilizam para navegar por essa trajetória e, crucialmente, para escapar de ótimos locais, podem ser drasticamente diferentes. A suíte selecionada inclui dois dos mais influentes e distintos representantes deste paradigma: Simulated Annealing (SA) e Iterated Local Search (ILS).

Simulated Annealing (SA): A Trajetória Probabilística

O Simulated Annealing (SA) introduziu uma abordagem radicalmente nova para escapar de ótimos locais. Em vez de depender de movimentos determinísticos ou puramente aleatórios, ele emprega um critério de aceitação probabilístico que permite, ocasionalmente, movimentos para soluções de pior qualidade (ou seja, com maior custo).⁷ Essa capacidade é o que permite ao algoritmo "subir o morro" para escapar de vales no cenário de busca e explorar outras regiões do espaço de soluções. A probabilidade de aceitar um movimento de piora é controlada por um parâmetro chamado "temperatura" (

T), que é gradualmente reduzido ao longo da busca, em um processo análogo ao

recozimento (annealing) de metais na metalurgia.¹ No início, com alta temperatura, movimentos de piora são aceitos com maior probabilidade, promovendo a exploração (diversificação). À medida que a temperatura diminui, o critério de aceitação se torna mais restritivo, favorecendo a exploração de mínimos locais (intensificação).¹

A inclusão do SA é justificada por sua contribuição seminal, que representou uma mudança de paradigma na forma como a busca local era concebida.

3.

Snippet de código

```
@article{Kirkpatrick1983,  
  author = {S. Kirkpatrick and C. D. Gelatt Jr. and M. P. Vecchi},  
  title = {Optimization by Simulated Annealing},  
  journal = {Science},  
  volume = {220},  
  number = {4598},  
  pages = {671--680},  
  year = {1983},  
  doi = {10.1126/science.220.4598.671}  
}
```

- **Relevância:** Este é o artigo seminal publicado na revista *Science* que introduziu o Simulated Annealing na comunidade de otimização.¹³ Sua importância fundamental reside na "conexão profunda e útil entre a mecânica estatística [...] e a otimização combinatória".¹⁴ Antes do SA, as estratégias para escapar de ótimos locais eram frequentemente ad-hoc. Kirkpatrick e seus coautores não apenas propuseram um novo mecanismo de escape; eles importaram um processo físico bem compreendido — o recozimento de sólidos para atingir estados de energia mínima — e seu formalismo matemático. Isso forneceu um método com base em princípios, controlável e com provas de convergência assintótica para o ótimo global. A seleção do SA é, portanto, justificada porque ele representa o paradigma de uma busca por trajetória controlada por um critério de aceitação probabilístico, fundamentado em uma poderosa e elegante analogia física, que mudou a forma como os pesquisadores abordam o desafio de escapar de ótimos locais.

Iterated Local Search (ILS): A Trajetória Baseada em Perturbação

O Iterated Local Search (ILS) representa uma filosofia diferente dentro do paradigma de busca por trajetória. Em vez de tomar pequenas decisões probabilísticas a cada passo, como o SA, o ILS opera em um nível mais estratégico. É um framework que itera entre duas fases principais: uma fase de *Perturbação*, que aplica uma modificação forte na solução atual para movê-la para uma bacia de atração diferente no espaço de soluções, e uma fase de *Busca Local*, que intensifica a busca a partir dessa nova solução para encontrar o ótimo local correspondente.¹⁶ O resultado da busca local é então avaliado por um

Critério de Aceitação para decidir qual solução (a nova ou a anterior) servirá como ponto de partida para a próxima iteração.¹⁶

A distinção entre SA e ILS é crucial para a justificativa metodológica. Enquanto a inteligência do SA está encapsulada em sua função de probabilidade de aceitação, a inteligência do ILS reside em sua estrutura de alto nível, que desacopla explicitamente os mecanismos de diversificação (Perturbação) e intensificação (Busca Local). Isso torna o ILS um framework altamente modular e flexível, onde o pesquisador pode projetar e "conectar" diferentes heurísticas para cada um de seus componentes.

4.

Snippet de código

```
@incollection{Lourenco2019,  
  author = {Helena R. Lourenço and Olivier C. Martin and Thomas Stutzle},  
  title = {Iterated Local Search: Framework and Applications},  
  booktitle = {Handbook of Metaheuristics},  
  editor = {Michel Gendreau and Jean-Yves Potvin},  
  series = {International Series in Operations Research & Management Science},  
  volume = {272},  
  pages = {129--168},  
  publisher = {Springer},
```



```
year    = {2019},  
doi      = {10.1007/978-3-319-91086-4_5}  
}
```

- **Relevância:** Este capítulo do *Handbook of Metaheuristics* é a referência moderna e definitiva que formaliza o ILS como um framework.¹⁷ Ele articula claramente os quatro componentes essenciais (GenerateInitialSolution, LocalSearch, Perturbation, AcceptanceCriterion) e posiciona o ILS não como um algoritmo único, mas como um modelo simples, poderoso e amplamente aplicável para a construção de meta-heurísticas de alto desempenho.¹⁶ A inclusão do ILS na suíte é justificada porque ele representa uma abordagem pragmática e de engenharia para a busca por trajetória. Ele exemplifica o paradigma de combinar sistematicamente perturbação e busca local, uma estratégia que é a espinha dorsal de muitos dos algoritmos de otimização mais eficazes da atualidade. A escolha conjunta de SA e ILS, portanto, permite a comparação de duas filosofias de busca por trajetória fundamentalmente diferentes: uma baseada em um controle probabilístico micro-gerenciado e outra em uma orquestração estratégica de alto nível de heurísticas de diversificação e intensificação.

O Paradigma Construtivo: GRASP

Diferentemente dos métodos de busca por trajetória ou populacionais, que operam sobre soluções completas, as meta-heurísticas construtivas constroem soluções a partir do zero, adicionando componentes um a um até que uma solução completa seja formada.¹ A Greedy Randomized Adaptive Search Procedure (GRASP) é o principal representante deste paradigma.

O GRASP é uma meta-heurística multi-start, o que significa que executa múltiplas iterações independentes a partir de diferentes pontos de partida. Cada iteração do GRASP consiste em duas fases distintas ⁸:

1. **Fase de Construção:** Uma solução viável é construída de forma iterativa. Em cada passo da construção, em vez de escolher deterministicamente o melhor componente para adicionar (como faria uma heurística puramente gulosa), o GRASP cria uma *Lista de Candidatos Restrita* (RCL) contendo os melhores candidatos. Um elemento é então selecionado aleatoriamente desta lista. Este

processo "guloso aleatorizado" introduz diversidade, permitindo a construção de uma ampla variedade de soluções iniciais de alta qualidade.¹⁹

2. **Fase de Busca Local:** A solução construída na primeira fase é usada como ponto de partida para um procedimento de busca local, que a refina até que um ótimo local seja alcançado.⁹ A melhor solução encontrada em todas as iterações é mantida como o resultado final.

A característica que define o GRASP e o posiciona no paradigma construtivo é sua inovadora fase de construção. É a maneira como ele *constrói* soluções que o diferencia de outros métodos multi-start que poderiam usar soluções iniciais puramente aleatórias.

5.

Snippet de código

```
@article{Feo1995,  
  author = {Thomas A. Feo and Mauricio G. C. Resende},  
  title = {Greedy randomized adaptive search procedures},  
  journal = {Journal of Global Optimization},  
  volume = {6},  
  number = {2},  
  pages = {109--133},  
  year = {1995},  
  doi = {10.1007/BF01096763}  
}
```

- **Relevância:** Este é o artigo seminal que introduziu e formalizou a metodologia GRASP.¹⁹ Ele estabeleceu o conceito central de usar uma RCL para equilibrar a ganância (greedy) e a aleatoriedade (randomization) durante a fase de construção. Esta abordagem permite que o GRASP gere pontos de partida diversos e de alta qualidade para a fase de busca local, explorando efetivamente diferentes regiões do espaço de soluções. A seleção do GRASP é justificada porque ele exemplifica o paradigma de como construir soluções de forma inteligente a partir do zero.

É importante notar que, embora sua característica definidora seja construtiva, o

GRASP é inerentemente um híbrido. A fase de construção é projetada explicitamente para alimentar a fase de busca local; o sucesso do método depende da sinergia entre as duas.⁹ Essa natureza híbrida não enfraquece sua classificação como representante do paradigma construtivo; pelo contrário, ela o posiciona como uma ponte natural entre os paradigmas. O GRASP demonstra como um núcleo construtivo pode ser efetivamente integrado a uma estrutura de busca por trajetória (a busca local), tornando-o um exemplo precoce e bem-sucedido de hibridização e reforçando a importância de estudar esses paradigmas fundamentais tanto isoladamente quanto em combinação.

Síntese e Justificativa Conclusiva

A seleção de algoritmos para um estudo comparativo em otimização não deve ser uma questão de conveniência, mas sim uma decisão metodológica fundamentada. Este relatório forneceu uma justificativa bibliográfica detalhada para a escolha de uma suíte composta por Algoritmo Genético (GA), Simulated Annealing (SA), Iterated Local Search (ILS) e GRASP. O argumento central é que este conjunto oferece uma cobertura abrangente e representativa dos três principais paradigmas de meta-heurísticas: populacional, de busca por trajetória e construtivo.

A análise demonstrou que cada algoritmo selecionado é um exemplar canônico de sua respectiva classe, com sua importância firmemente estabelecida na literatura através de obras seminais e de referência:

- O **Algoritmo Genético**, fundamentado na teoria dos esquemas de Holland¹⁰, representa o paradigma populacional, que explora o espaço de soluções através da recombinação de blocos de construção promissores.
- O **Simulated Annealing**, com sua base na mecânica estatística introduzida por Kirkpatrick et al.¹⁴, e o **Iterated Local Search**, com seu framework modular de perturbação e intensificação formalizado por Lourenço et al.¹⁷, representam duas filosofias distintas e influentes dentro do paradigma de busca por trajetória.
- O **GRASP**, introduzido por Feo e Resende¹⁹, exemplifica o paradigma construtivo através de seu inovador processo de construção guloso-aleatorizado, ao mesmo tempo que serve como uma ponte para outros paradigmas através de sua fase de busca local.

A força desta seleção reside no estabelecimento de *baselines* robustos e defensáveis. Ao avaliar o desempenho desses quatro algoritmos arquetípicos, um pesquisador pode obter um sinal claro sobre quais estratégias de busca fundamentais são mais eficazes para a estrutura do problema em questão. Esta abordagem permite uma análise mais profunda do que uma simples classificação de algoritmos por desempenho; ela oferece insights sobre *por que* certos algoritmos se saem melhor, conectando seu sucesso à sua filosofia de busca subjacente.

Além disso, esta seleção metodológica serve como uma plataforma sólida para pesquisas futuras. Uma vez que o desempenho dos paradigmas fundamentais é compreendido, investigações subsequentes podem logicamente proceder para explorar híbridos mais complexos, como algoritmos meméticos ⁵, ou algoritmos mais recentes, com um entendimento claro de quais componentes (por exemplo, um mecanismo de perturbação do tipo ILS ou um operador de cruzamento do tipo GA) são mais propensos a serem eficazes. Isso demonstra um plano de pesquisa estruturado e com visão de futuro.

Em conclusão, a escolha de GA, SA, ILS e GRASP transcende a seleção de quatro algoritmos individuais. Representa uma estratégia metodológica deliberada e sólida para decompor um problema de otimização complexo, testando a eficácia de filosofias de solução fundamentalmente diferentes. Esta abordagem garante a relevância, a profundidade e a longevidade dos resultados da pesquisa, fornecendo uma base sólida sobre a qual o conhecimento futuro pode ser construído.

Referências citadas

1. Metaheuristics - Scholarpedia, acessado em julho 24, 2025, <http://www.scholarpedia.org/article/Metaheuristics>
2. Michel Gendreau · Jean-Yves Potvin Editors Third Edition, acessado em julho 24, 2025, http://old.math.nsc.ru/LBRT/k5/OR-MMF/2019_Book_HandbookOfMetaheuristics.pdf
3. Handbook of Metaheuristics, Second Edition (International Series in Operations Research & Management Science, Volume 146) - National Academic Digital Library of Ethiopia, acessado em julho 24, 2025, <http://ndl.ethernet.edu.et/bitstream/123456789/20494/1/149.pdf>
4. METAHEURISTICS - OptTek Systems, acessado em julho 24, 2025, <https://www.opttek.com/sites/default/files/Metaheuristics.pdf>
5. Handbook of Metaheuristics | Request PDF - ResearchGate, acessado em julho 24, 2025, https://www.researchgate.net/publication/265303019_Handbook_of_Metaheuristics

6. Heuristics for Multi-Attribute Vehicle Routing Problems : A Survey and Synthesis, acessado em julho 24, 2025, https://www.researchgate.net/publication/229429609_Heuristics_for_Multi-Attribute_Vehicle_Routing_Problems_A_Survey_and_Synthesis
7. Metaheuristics for the Vehicle Routing Problem and its Extensions : A Categorized Bibliography - Cirrelt, acessado em julho 24, 2025, <https://www.cirrelt.ca/documentstravail/cirrelt-2007-27.pdf>
8. GRASP Optimization for the Strip Packing Problem with Flags, Waste Functions, and an Improved Restricted Candidate List - MDPI, acessado em julho 24, 2025, <https://www.mdpi.com/2076-3417/12/4/1965>
9. A metaheuristic to support the distribution of COVID-19 vaccines - SciELO, acessado em julho 24, 2025, <https://www.scielo.br/j/prod/a/9bdJcGvPmqP4wMcLshqkLFM/>
10. Adaptation in Natural and Artificial Systems: An Introductory Analysis with - Google Books, acessado em julho 24, 2025, https://books.google.com/books/about/Adaptation_in_Natural_and_Artificial_Sys.html?id=JE5RAAAAMAAJ
11. Adaptation in natural and artificial systems: An introductory analysis with applications to biology, control, and artificial intelligence | BibSonomy, acessado em julho 24, 2025, <https://www.bibsonomy.org/bibtex/2cc34fc2f76d00e1368ac7e6bcd4904d5/jacquenot>
12. Adaptation in Natural and Artificial Systems: An Introductory Analysis with Applications to Biology, Control, and Artificial Intelligence | Books Gateway - MIT Press Direct, acessado em julho 24, 2025, <https://direct.mit.edu/books/monograph/2574/Adaptation-in-Natural-and-Artificial-SystemsAn>
13. (PDF) Simulated Annealing - ResearchGate, acessado em julho 24, 2025, https://www.researchgate.net/publication/38363197_Simulated_Annealing
14. Optimization by Simulated Annealing | BibSonomy, acessado em julho 24, 2025, <https://www.bibsonomy.org/bibtex/29ba1c0e7e15e7686aaddc5161249c973/lopusz>
15. Stochastic Search | Books | Vol , No - ASCE Library, acessado em julho 24, 2025, <https://ascelibrary.org/doi/10.1061/9780784402207.apf>
16. Evolutionary Algorithm-Based Iterated Local Search Hyper-Heuristic for Combinatorial Optimization Problems - MDPI, acessado em julho 24, 2025, <https://www.mdpi.com/1999-4893/15/11/405>
17. An iterated local search for the travelling salesman problem | Anais ..., acessado em julho 24, 2025, <https://sol.sbc.org.br/index.php/eniac/article/view/18427>
18. An Iterated Local Search Heuristic for the Multi-Trip Vehicle Routing Problem with Multiple Time Windows - MDPI, acessado em julho 24, 2025, <https://www.mdpi.com/2227-7390/12/11/1712>
19. The Perfect Awareness Problem - Benchmark Instances - IC-Unicamp, acessado em julho 24, 2025, <https://www.ic.unicamp.br/~cid/Problem-instances/Perfect-Awareness-Problem/>
20. Less is more: simple algorithms for the minimum sum of squares clustering

problem | IMA Journal of Management Mathematics | Oxford Academic,
acessado em julho 24, 2025,

<https://academic.oup.com/imaman/article/33/3/531/6354727>

21. A Local Search Algorithm for Large Maximum Weight Independent Set Problems -
DROPS, acessado em julho 24, 2025,

<https://drops.dagstuhl.de/entities/document/10.4230/LIPIcs.ESA.2022.45>